TDC SUMMIT SP 2026

AI for FinOps na prática

AWS Cost Anomaly Detection + Cost Optimization Hub + Amazon Q

Felipe KiKo

O problema real

Custos sobem...e quase todo mundo percebe tarde demais

O ciclo do incidente de custo

COMO É

- Alerta chega com **2–5 dias de atraso**
- Investigação manual: consoles, relatórios, Slack, etc...
- Reuniões para descobrir "quem mexeu no quê"

O QUE QUEREMOS

- Detectar desvio **em horas**
- Entender causa em **minutos**
- Agir com contexto e rastreabilidade
- FinOps como operação **contínua**, e não reação

A maioria das organizações demora + ou - 2 semanas para fechar o ciclo de "anomalia → ação"

E como? Exemplo prático de Playbook

1. **Detectar: AWS Cost Anomaly Detection**
   Monitores gerenciados, alertas e suporte a accounts / tags / categories
2. **Priorizar: Cost Optimization Hub**
   Cost Efficiency como KPI e separando incidente de otimização
3. **Investigar: Amazon Q**
   Perguntas em linguagem natural sobre billing e custo

Mas antes...FinOps não é só cortar custo

> *"FinOps é uma disciplina de gestão financeira de cloud que permite às equipes maximizar valor de negócio, tomando decisões informadas sobre tradeoffs entre velocidade, custo e qualidade."*
> *— FinOps Foundation*

A dor que todo mundo sente

- Multi-account, multi-serviço, multi-time...**multi** tudo!
- Custo raramente tem **um** motivo
- Engenharia + Produto + Finanças falam línguas **diferentes**
- A IA ajuda a **traduzir e acelerar**, mas não substitui julgamento

Passo 1: Detectar

AWS Cost Anomaly Detection

AWS Cost Anomaly Detection

O QUE É

- Serviço que usa ML para detectar padrões anômalos de gasto
- Compara spend atual com baseline histórico por dimensão
- Envia alertas via **SNS ou E-mail**

TIPOS DE MONITOR

- **AWS Services**: por serviço (ex: EC2, RDS)
- **Linked Account**: por conta AWS
- **Cost Category**: agrupamentos customizados
- **Cost Allocation Tags**: por tag (ex: `team`, `env`)

Anatomia de uma anomalia

O QUE O ALERTA TRAZ:

```
Anomaly detected: EC2 - us-east-1
Account: 123456789012 (prod-api)
Period: 2026-04-10 → 2026-04-12

Expected spend: $1,240 / day
Actual spend:   $4,870 / day
Impact: +$7,890 total

Root cause candidates:
  • Instance type: p3.16xlarge
  • Usage type: BoxUsage:p3.16xlarge
  • Region: us-east-1
```

Boas práticas de configuração

- **Threshold**: Combine valor absoluto + % para evitar ruído
- **Granularidade**: Diária para times de engenharia
- **Alertas**: Slack, Teams, Chat via SNS → menos e-mail ignorado
- **Tags obrigatórias**: `team`, `env`, `product`, ...

IMPORTANTE: Anomalia sem tag = investigação cega

Passo 2: Priorizar

AWS Cost Optimization Hub

AWS Cost Optimization Hub

O QUE É

Painel centralizado que **agrega e prioriza** recomendações de custo de múltiplos serviços AWS em um único lugar.

FONTES

- Compute Optimizer
- Trusted Advisor
- Savings Plans recommendations
- Reserved Instance recommendations
- RDS, EBS, Lambda, Fargate...

PARA QUE SERVE AQUI

- Separar **incidente** (anomalia) de **oportunidade contínua**
- Priorizar por impacto financeiro real
- Dar contexto antes de chamar o Amazon Q

Incidente vs. Otimização Contínua

	ANOMALIA (INCIDENTE)	OPORTUNIDADE (HUB)
Origem	Desvio do baseline ML	Rightsizing, Savings Plans
Urgência	Alta: Agir hoje	Média: Planejar sprint
Ator	Engenharia + FinOps	FinOps + Arquitetura
Ferramenta	Anomaly Detection + Q	Cost Optimization Hub
KPI	MTTR, impacto $$	Cost Efficiency Score

Tratar uma anomalia como oportunidade de rightsizing causa **confusão de prioridade**...separe os fluxos antes de investigar

Passo 3: Investigar

Amazon Q

Amazon Q para Custos

O QUE É...NO CONTEXTO DE BILLING!

- **IMPORTANTE:** Antes, Q Developer!
- Interface de linguagem natural integrada ao **AWS Cost Management**
- Acessa dados do **Cost Explorer, Cost & Usage Report (CUR), Savings Plans, Reserved Instances**
- Responde perguntas sobre **contas, serviços, tags, cost categories e períodos**
- Gera **insights** sem precisar escrever queries no Athena

Amazon Q usa o contexto do Cost Explorer com permissões do usuário...ele não "acha" dados que você não tem acesso

Como o Q responde perguntas de custo

CAPACIDADES CONFIRMADAS

- Comparar spend **período vs período**
- Detalhar por **serviço, conta, região, tag**
- Identificar **top N serviços** por crescimento
- Explicar variações em **cost categories**
- Sugerir próximos passos (rightsizing, Savings Plans)

LIMITES IMPORTANTES

- Sem acesso a logs de infra (CloudTrail, CloudWatch)
- Sem contexto de deploys ou tickets (ex.: Jira, Trello, etc..)
- Responde com dados de billing, mas a **interpretação é sua**

Prompt engineering para custo

```
❌ Ruim:
"Por que meu custo aumentou?"


✅ Melhor:
"Compare o custo de EC2 em us-east-1 entre 1-7 Abril e 8-14 Abril, detalhado
por usage type e conta. Mostre as top 3 variações absolutas em USD."


✅✅ Melhor ainda:
"[contexto acima] + A conta prod-data teve anomalia de +$14k.
O que mudou nessa conta nesse período?"
```

Perguntas que eu faria ao Amazon Q

Compare os custos dos últimos 7 dias com os 7 dias anteriores para a cost category X e mostre os maiores drivers.

Quais contas, serviços e tags explicam 80% do aumento no período?

Existe correlação com novas recomendações no Cost Optimization Hub ou mudança de cobertura/utilização de Savings Plans?

Monte um resumo executivo com causa provável, impacto e próximos passos.

Da investigação à ação

O QUE O AMAZON Q ENTREGA

PARA TIME DE ENGENHARIA

- Qual recurso/serviço gerou o custo
- Em qual conta e região
- Qual tag ou categoria (= qual time)
- Comparação período anterior

PARA TIME DE FINOPS

- Impacto financeiro quantificado
- Se é anomalia ou tendência
- Oportunidade de Savings Plans / RI
- Baseline esperado pós-correção

Use a resposta do Q como **draft do ticket / post-mortem**. Copie os dados, adicione contexto de infra, assine com o time responsável...rastreabilidade garantida!

A Dor do MTTD e MTTR

- Mean Time to Detect (MTTD): Quanto tempo leva para você saber do desvio?
- Mean Time to Resolve (MTTR): A IA entra para reduzir o tempo entre o alerta e a ação
- Detecção Lenta: Custos raramente explodem por um "único motivo" fácil de ver
- Investigação Manual: Horas cruzando Tags, Contas e UsageTypes no Cost Explorer

MTTD

Meta: < 8 horas
do fato até o alerta

MTTR

Meta: < 4 horas
do alerta à ação

≥90%

Recursos com tags
obrigatórias

Takeaways

O que você leva daqui

3 FERRAMENTAS, 1 FLUXO

- **Anomaly Detection** → detecta o "o quê"
- **Cost Optimization Hub** → prioriza o "agora ou depois"
- **Amazon Q** → explica o "por quê"

A IA não decide...você decide!

O Q dá dados estruturados e interpretação preliminar. A decisão de agir (parar uma instância, escalar uma conversa com o time, abrir um post-mortem) ainda é humana e requer contexto de negócio.

Referências

AWS: DOCUMENTAÇÃO OFICIAL

- **Amazon Q para Cost Management**
  `docs.aws.amazon.com/cost-management/latest/userguide/ce-q-overview.html`
- **Cost Optimization Hub: Cost Efficiency Metric**
  `aws.amazon.com/about-aws/whats-new/2025/11/aws-cost-optimization-hub-cost-efficiency-metric-measure-track/`
- **Anomaly Detection: Managed Monitors**
  `aws.amazon.com/about-aws/whats-new/2025/11/aws-cost-anomaly-detection-managed-monitoring`

FINOPS FOUNDATION

- **FinOps Framework & Capabilities**
  `finops.org/framework`
- **Anomaly Management Capability**
  `finops.org/framework/capabilities/anomaly-management`

Dúvidas?

Obrigado!