FABRICIO VERONEZ

Reduzir custos na AWS com IA: Antes da fatura chegar

Felipe KiKo

O problema real

Custos sobem...e quase todo mundo percebe tarde demais

O ciclo do incidente de custo

COMO É

- Alerta chega com **2–5 dias de atraso**
- Investigação **manual**: consoles, relatórios, mensagens, etc...
- **Reuniões** para descobrir "quem mexeu no quê"

O QUE QUEREMOS

- Detectar desvio **em horas**
- Entender causa em **minutos**
- Agir com **contexto** e **rastreabilidade**
- FinOps como operação **contínua**... não reativa

A maioria das organizações demora + ou - 2 semanas para fechar o ciclo de "anomalia → ação → causa-raiz"

E como? Exemplo prático de Playbook

1. **Detectar: AWS Cost Anomaly Detection**
   Monitores gerenciados, alertas e suporte a accounts / tags / categories
2. **Priorizar: Cost Optimization Hub**
   Cost Efficiency como KPI e separando incidente de otimização
3. **Investigar: Kiro**
   Perguntas em linguagem natural sobre billing e custo

Mas antes...FinOps não é só cortar custo

> *"FinOps é uma disciplina de gestão financeira de cloud que permite às equipes maximizar valor de negócio, tomando decisões informadas sobre tradeoffs entre velocidade, custo e qualidade."*
> *— FinOps Foundation*

A dor que todo mundo sente

- Multi-account, multi-serviço, multi-time...**multi** tudo!
- Custo raramente tem **um** motivo
- Engenharia + Produto + Finanças falam línguas **diferentes**
- A IA ajuda a **traduzir** e **acelerar**, mas não substitui julgamento

Passo 1: Detectar

AWS Cost Anomaly Detection

AWS Cost Anomaly Detection

O QUE É

- Serviço que usa ML para detectar padrões anômalos de gasto
- Compara spend atual com baseline histórico por dimensão
- Pode enviar alertas via **SNS** ou **E-mail**

TIPOS DE MONITOR

- **AWS Services**: Por serviço (ex: EC2, RDS)
- **Linked Account**: Por conta AWS
- **Cost Category**: Agrupamentos customizados
- **Cost Allocation Tags**: Por tag (ex: `team`, `env`)

Anatomia de uma anomalia

O QUE O ALERTA TRAZ:

```
Anomaly detected: EC2 - us-east-1
Account: 123456789012 (prod-api)
Period: 2026-10-10 → 2026-10-12

Expected spend: $1,240 / day
Actual spend:   $4,870 / day
Impact: +$7,890 total

Root cause candidates:
  • Instance type: p3.16xlarge
  • Usage type: BoxUsage:p3.16xlarge
  • Region: us-east-1
```

Boas práticas de configuração

- **Threshold**: Combine valor absoluto + % para evitar ruído
- **Granularidade**: Diária para times de engenharia
- **Alertas**: Slack, Teams, Chat via SNS → menos e-mail ignorado
- **Tags obrigatórias**: `team`, `env`, `product`, ...

IMPORTANTE: Anomalia sem tag = investigação cega

Bora vê?

- **Serviço:**

  `aws.amazon.com/aws-cost-management/aws-cost-anomaly-detection/`

- Exemplos:

  `aws.amazon.com/blogs/aws-cloud-financial-management/preview-anomaly-detection-and-alerting-now-available-in-aws-cost-management/`

  `aws.amazon.com/blogs/aws-cloud-financial-management/announcing-general-availability-of-aws-cost-anomaly-detection/`

Passo 2: Priorizar

AWS Cost Optimization Hub

AWS Cost Optimization Hub

O QUE É

Painel centralizado que **agrega** e **prioriza** recomendações de custo de múltiplos serviços AWS em um único lugar

FONTES

- Compute Optimizer
- Trusted Advisor
- Savings Plans recommendations
- Reserved Instance recommendations
- RDS, EBS, Lambda, Fargate...

PARA QUE SERVE AQUI

- Separar **incidente** (anomalia) de **oportunidade contínua**
- Priorizar por **impacto** financeiro real
- Dar **contexto** antes de chamar o **Kiro**

Incidente vs. Otimização Contínua

	ANOMALIA (INCIDENTE)	OPORTUNIDADE (HUB)
Origem	Desvio do baseline ML	Rightsizing, Savings Plans
Urgência	Alta: Agir hoje	Média: Planejar sprint
Ator	Engenharia + FinOps	FinOps + Arquitetura
Ferramenta	Anomaly Detection + Kiro	Cost Optimization Hub
KPI	MTTR, impacto $$	Cost Efficiency Score

Tratar uma anomalia como oportunidade de rightsizing causa **confusão de prioridade**...separe os fluxos antes de investigar

Bora vê?

- **Serviço:**

  `aws.amazon.com/aws-cost-management/cost-optimization-hub/`

- Exemplo:

  `aws.amazon.com/blogs/aws/new-cost-optimization-hub-to-find-all-recommended-actions-in-one-place-for-saving-you-money/`

Passo 3: Investigar

Kiro

Kiro para Custos

O QUE É...NO CONTEXTO DE BILLING!

- Interface de linguagem natural integrada aos **serviços da AWS**
- Acessa dados do **CUR, Savings Plans, Reserved Instances**...
- Responde perguntas sobre **contas, serviços, tags, cost categories e períodos**
- Gera **insights** sem precisar escrever queries no Athena

O Kiro pode usar o contexto do Cost Explorer com permissões do usuário...ele não "acha" dados que você não tem acesso

Como o Kiro responde perguntas de custo

CAPACIDADES CONFIRMADAS

- Comparar spend **período vs período**
- Detalhar por **serviço, conta, região, tag**
- Identificar **top N serviços** por crescimento
- Explicar variações em **cost categories**
- Sugerir próximos passos (rightsizing, Savings Plans)

LIMITES IMPORTANTES

- Sem contexto de deploys ou tickets (ex.: Jira, Trello, etc..)
- Responde com dados de billing, mas a **interpretação é sua**

Prompt engineering para custo

❌ Ruim:
"Por que meu custo aumentou?"

✅ Melhor:
"Compare o custo de EC2 em us-east-1 entre 1-7 SET e 8-14 SET, detalhado por usage type e conta. Mostre as top 3 variações absolutas em USD."

✅✅ Melhor ainda:
"[contexto acima] + A conta prod-data teve anomalia de +$14k.
O que mudou nessa conta nesse período?"

Perguntas que eu faria para o Kiro

Compare os custos dos últimos 7 dias com os 7 dias anteriores
para a cost category X e mostre os maiores drivers.

Quais contas, serviços e tags explicam 80% do aumento no período?

Existe correlação com novas recomendações no Cost Optimization Hub
ou mudança de cobertura/utilização de Savings Plans?

Monte um resumo executivo com causa provável, impacto e próximos passos.

Da investigação à ação

O QUE O KIRO ENTREGA

PARA TIME DE ENGENHARIA

- Qual recurso / serviço gerou o custo
- Em qual conta e região
- Qual tag ou categoria (= qual time)
- Comparação período anterior

PARA TIME DE FINOPS

- Impacto financeiro quantificado
- Se é anomalia ou tendência
- Oportunidade de Savings Plans / RI
- Baseline esperado pós-correção

Use a resposta do Kiro como **draft do ticket / post-mortem**. Copie os dados, adicione contexto de infra, assine com o time responsável... rastreabilidade garantida!

A Dor do MTTD e MTTR

- Mean Time to **Detect** (MTTD): Quanto tempo leva para você saber do desvio?
- Mean Time to **Resolve** (MTTR): A IA entra para reduzir o tempo entre o alerta e a ação
- Detecção Lenta: Custos raramente explodem por um "único motivo" fácil de ver
- Investigação Manual: Horas cruzando Tags, Contas e UsageTypes no Cost Explorer

MTTD

Meta: < 8 horas
do fato até o alerta

MTTR

Meta: < 4 horas
do alerta à ação

≥90%

Recursos com tags
obrigatórias

Bora vê?

- **Serviço:**

  `kiro.dev`

- Exemplos:

  `aws.amazon.com/blogs/aws-cloud-financial-management/5-ways-to-use-amazon-q-to-optimize-your-infrastructure/`

  `builder.aws.com/content/3CO7oQokrPh5POx8bihtas6oLUA/unlock-aws-cost-efficiency-with-kiro`

Updates

Em breve...

- Amazon Q será descontinuado, **Kiro** vem para ficar!

  `aws.amazon.com/blogs/devops/amazon-q-developer-end-of-support-announcement/`

- Camada de agentes de IA com o **AWS FinOps Agent** (preview)

  `aws.amazon.com/finops-agent/`

- Crie um **limite de gastos** na sua conta AWS

  `docs.aws.amazon.com/accounts/latest/reference/create-spend-limit.html`

Takeaways

O que você leva daqui

3 FERRAMENTAS, 1 FLUXO

- **Anomaly Detection** → detecta o "o quê"
- **Cost Optimization Hub** → prioriza o "agora ou depois"
- **Kiro** → explica o "por quê"

A IA não decide...você decide! Ela te dá dados estruturados e interpretação preliminar. A decisão de agir (parar uma instância, escalar uma conversa com o time, abrir um post-mortem) ainda é humana e requer contexto de negócio.

Referências

AWS: DOCUMENTAÇÃO OFICIAL

- Cost Optimization Hub: Cost Efficiency Metric
  `aws.amazon.com/about-aws/whats-new/2025/11/aws-cost-optimization-hub-cost-efficiency-metric-measure-track/`
- Anomaly Detection: Managed Monitors
  `aws.amazon.com/about-aws/whats-new/2025/11/aws-cost-anomaly-detection-managed-monitoring`

FINOPS FOUNDATION

- FinOps Framework & Capabilities
  `finops.org/framework`
- Anomaly Management Capability
  `finops.org/framework/capabilities/anomaly-management`

Dúvidas?

Obrigado!

